

高斯读噪下直接、两级与周期压扩量化的动态范围与低阶相位统计

Dynamic Range and Low-Order Phase Statistics of Direct, Two-Stage, and Periodic Companding Quantization under Gaussian Read Noise

姜尧耕 <https://y-g-jiang.github.io>

摘要—本文研究线性输入经直接目标量化、整数码流再量化和周期压扩量化后的低阶条件相位统计。在加性、独立同分布、标准差 $\sigma > 0$ 的零均值高斯噪声和最近邻标量化假设下，核心参数为无量纲比值 $r = \sigma/\Delta$ 。本文给出直接量化一阶条件均值偏差和二阶误差能量的完整傅里叶级数、截断余项界与容差阈值；对 $16 \rightarrow 14$ bit 的 ties-to-even 再量化建立精确离散转移模型，并证明其 5,3 交替单元有别于均匀 Q_4 的相位平移。一阶指标统一取相对理想信号的最大条件均值绝对偏差，并按 14-bit 量化步长归一；二阶指标取按均匀量化误差方差归一的相位半极差。容差统一取 1% 时，两级链路的一阶、二阶阈值分别为 $r = 0.805, 1.274$ ，直接量化对应为 $0.419, 0.620$ 。对一般周期压扩表，分离最小重复长度造成的高斯阻尼与组宽、判决边界和重建值造成的傅里叶前因子，并给出完整前因子和尾界。相位平均失真与平滑压扩曲线的领先阶偏置作为已知结果重述。对于非高斯噪声，本文根据独立帧差推导直接最近邻量化一、二阶相位半极差的下界。四帧 GFX100 暗场数据表明，ADC 后整数码差分具有重尾和空间相位异质性。

Index Terms—RAW 位深；再量化；量化噪声；非减法型抖动；条件矩；傅里叶级数；ties-to-even；压扩

I. 引言

编码精度的意义建立在其承载的信号信息上。传感器时间读噪与散粒噪声 (shot noise) 会使最低几位逐帧摆动；像素响应不均匀性 (PRNU)、暗信号不均匀性 (DSNU)、黑场校正残差及后续链路还可能引入固定或相关结构。前一类随机项能够打散量化相位，此时若直接截位到低位，数值上的空格不必然对应稳定的量化相位结构，极端情形类似二值半调。

量化误差是输入的确定性函数；加性独立量化噪声模型对各阶矩成立需要满足特定条件 [1]。因此本文给定 s 和读噪 N ，研究条件分布 $P(Y_b | s)$ 及其各阶条件矩，以刻画读噪对确定性结构的削弱程度。

独立研究者。作者预印本，版本日期：2026-08-22；未经同行评审。

设理想线性原始 (RAW) 信号为 s ，输出位深为 b ，量化输出为 Y_b 。我们关心的是输出相对理想信号的误差

$$e_b(s) = Y_b - s.$$

本文所称两个位深 b_1, b_2 对给定信号相似，专指以下三个低阶口径；条件分布距离属于另一层次的判据：

1. 指定目标信噪比 (SNR) 下，以信噪比定义动态范围 (DR) 损失低于给定容差；
2. 条件均值偏差 $B_b(s) = \mathbb{E}[Y_b - s | s]$ 低于给定容差；
3. 二阶误差能量 $M_{2,b}(s) = \mathbb{E}[(Y_b - s)^2 | s]$ 的量化相位调制低于给定容差；

三个口径分别度量信噪比损失、无限堆栈后的均值结构，以及零均值残差能量随量化相位的起伏。本文把条件均值、条件二阶矩等低阶条件统计量中随 $s \bmod \Delta$ 周期变化的部分称为低阶量化相位结构；其中一阶结构对应确定性均值偏置，二阶结构对应零均值残差的能量调制。

已有工作已经系统讨论 $\Delta^2/12$ 与 Sheppard 修正 [2]、高斯输入下的量化条件矩与包络 [3], [4], [5] 和 dither 设计准则 [6]。 σ/Δ 判据的相机语境解释见 [7], [8]；方差稳定压扩及其偏置 [9], [10], [11], [12]、量化的分辨率分析和非均匀量化失真 [13], [14]，以及有限精度链中的 double rounding [15] 也已有相应结果。

本文的技术增量集中在五点：在统一的条件相位记号和归一下给出截断余项界与容差阈值；建立指定 ties-to-even 两级链路的精确离散模型及容差阈值；推导一般周期整数表的傅里叶前因子、直流/相位分离和解析尾界；给出固定 4 倍整数重建约束的 δ 参数化、零直流等价条件和可达有限解析界；由独立帧差推导一般

加性噪声下直接最近邻量化的相位半极差下界。表 I 汇总了这些结果。

本文区分直接目标位深量化与先量化再舍入两条链路，分别定义为

$$\begin{aligned} Y_b^{\text{dir}} &= Q_{\Delta_b}(s + N), \\ Y_{14}^{\text{post}} &= T_{16 \rightarrow 14}(Q_1(s + N)), \\ T_{16 \rightarrow 14}(n) &= 4 \text{round}_{\text{even}}(n/4). \end{aligned} \quad (1)$$

16-bit 整数码降到 14-bit 时还需区分舍入规则。字面截位 $4\lfloor n/4 \rfloor$ 与普通 half-up 四舍五入 $4\lfloor n/4 + 1/2 \rfloor$ 在扣除各自的固定码值偏移后，都是直接 Q_4 的量化相位平移；二者的相位平均中心化误差能量、最坏相位幅度和任一相同目标 SNR 下的 DR 均与直接 Q_4 相同。ties-to-even 规则使半步整数码按粗码奇偶交替取向，所得量化单元宽度交替变化，不能化为一个固定偏移加相位平移。第 III、V 至 VII 节的闭式结果以 Y_b^{dir} 为对象，同时覆盖截位与 half-up 在上述中心化口径下的等价结果；第 VIII 节单列 ties-to-even 两级模型。

II. 经典框架：dither 与量化的特征函数

A. 量化输出的特征函数

设最近邻量化器

$$Q_{\Delta}(x) = \Delta \text{round}\left(\frac{x}{\Delta}\right),$$

作用在随机变量 X 上。Widrow 的统计量化理论给出量化输出的特征函数等于输入特征函数以 $\Psi = 2\pi/\Delta$ 为周期复制求和 [21], [22], [4]。下式采用 $\text{sinc}(x) = \sin(x)/x$ 。

$$\Phi_{Q_{\Delta}(X)}(u) = \sum_{l=-\infty}^{\infty} \Phi_X(u + l\Psi) \text{sinc}\left(\frac{\Delta(u + l\Psi)}{2}\right).$$

因此，量化误差里随 s 以量化网格为周期的条件统计量可在格点 $2\pi k/\Delta$ 处分析。一阶条件矩的第 k 个谐波正比于输入特征函数的格点值；更高阶条件矩还会出现特征函数导数及其组合。高斯特征函数的各阶导数均为多项式乘同一个高斯指数因子。当 $X = s + N$ 、读噪 N 与 s 独立时，

$$\Phi_X\left(\frac{2\pi k}{\Delta}\right) = e^{i2\pi k s/\Delta} \Phi_N\left(\frac{2\pi k}{\Delta}\right).$$

Sripad 和 Snyder 的格点条件给出量化误差边缘分布严格均匀的判据，即 $\Phi_X(2\pi l/\Delta) = 0, \forall l \neq 0$ [23]。跨样本白性还涉及输入样本对的联合特征函数；本文在标量格

点条件之外另行假设空间与帧间读噪独立。一般高斯输入的格点值不为零，但会随 $r = \sigma/\Delta$ 快速减小。III-A 节以 $A_2(r) = 12(4r^2 + 1/\pi^2)e^{-2\pi^2 r^2}$ 表示二阶首谐波相对于 $\Delta^2/12$ 的调制，第 VI 节给出完整二阶级数及其截断余项界。

B. 高斯读出噪声的抖动行为

对零均值高斯读噪 $N \sim \mathcal{N}(0, \sigma^2)$ 且 $\sigma > 0$ ，特征函数处处不为零，

$$\Phi_N\left(\frac{2\pi k}{\Delta}\right) = \exp\left[-\frac{1}{2}\left(\frac{2\pi k}{\Delta}\right)^2 \sigma^2\right] = \exp\left[-2\pi^2 k^2 \left(\frac{\sigma}{\Delta}\right)^2\right].$$

这个阻尼因子说明，高斯读噪不能把任何一阶矩调制严格清零（高斯特征函数没有实零点），但能有效压低第 k 个相位相干谐波。第 m 阶条件矩由 dither 特征函数及其至 $m-1$ 阶导数在格点 $2\pi k/\Delta$ 处的值决定，这是非减法型 dither 理论的定理 [17], [24]；本文第 V、VI 节取其高斯特例，给出闭式与截断余项界。非减法型 dither 的定义、可使低阶矩与输入严格独立的判据及其与本文高斯情形的差别，另见 [16], [25], [26]。记 $r = \sigma/\Delta$ ，主谐波 $k=1$ 的阻尼为 $e^{-2\pi^2 r^2}$ 。高斯输入下量化相位即其小数部分的分布可由同一周期卷积直接得到。

Clavier 等在 1947 年以特征函数方法给出正弦输入下均匀量化误差的谱 [27]；Bennett 在 1948 年给出高斯过程的对应结果，其中出现高斯阻尼；相关误差的白性还依赖输入的联合统计 [13]。本文据其中的标量格点阻尼推导条件矩。一般地，输入分布越平滑、格点特征函数越小，量化误差越接近量化定理给出的统计模型 [17]。在本文采用的高斯时间读噪模型中，特征函数在格点 $2\pi k/\Delta$ 处给出很强的指数衰减。

III. 量化步长、均匀量化噪声与 SNR-based DR

A. 步长与均匀量化噪声

统一用 16-bit 数字码值 (digital number, 记 DN16) 做单位，16-bit 最小步长 $\Delta_{16} = 1 \text{ DN16}$ ，直接 14-bit 目标量化的等效步长 $\Delta_{14} = 4 \text{ DN16}$ 。若改用 14-bit 模数转换单位 (analog-to-digital unit, ADU) 比较 14-bit 与更低位深 b ，量化步长为 $\Delta_b = 2^{14-b}$ 。本节 DR 公式均针对 Y_b^{dir} 。当量化误差与输入低协方差、量化相位又被噪声打散时，均匀量化噪声近似给出经典结果：

$$\sigma_{q,b}^2 = \frac{\Delta_b^2}{12}, \quad \sigma_{q,b} = \frac{\Delta_b}{\sqrt{12}}.$$

表 I
已有结果与本文增量

主题与最接近文献	已有结果	本文的技术增量
均匀量化条件矩 [3], [4], [5]	均值、均方值、高斯特例、最坏输入偏移与包络分析已有系统结果	统一写成逐点真值的相位级数, 并给出本文归一口径下的截断界和容差阈值
dither 条件与定量设计 [16], [17], [6]	特征函数格点条件、低阶矩独立条件及定量设计准则已有理论	取非减法型高斯特例并给出容差阈值
非高斯帧差检验 [18]	重复测量借助特征函数识别误差分布已有非参数方法; $\psi_D = \varphi_N ^2$ 是独立同分布差分的基本恒等式	由可识别的径向系数、单谐波极值界和 Parseval/Popoviciu 界给出直接最近邻量化的一、二阶相位半极差下界, 并用整数 RAW 检验 ADC 后码值差分
非均匀量化与平方根压扩 [13], [14], [9], [11], [19], [12]	高分辨率平均失真、连续曲线、压扩偏置, 以及按噪声尺度分组的整数查表已有分析	对任意有限周期直接积分其精确平均能量, 并给出周期整数表的有限傅里叶前因子、直流/相位双口径及 erfc/E_1 尾界; 另给固定 4 倍整数重建的 δ 参数化与可达有限界
ties-to-even 两级再量化 [20], [15]	舍入规则与 double rounding 现象均为既有结果	对指定 $Q_1 \rightarrow Q_4$ 整数复合映射给出 5, 3 单元、高斯条件矩和容差阈值

该低协方差近似用于信噪比计算。 $\Delta^2/12$ 需要量化相位被噪声充分随机化; 本文采用第 VI 节的完整结果。二阶误差能量首谐波的实际半幅为 $\Delta^2\delta(r)$, 其中

$$\delta(r) = \left(4r^2 + \frac{1}{\pi^2}\right) e^{-2\pi^2 r^2},$$

$$A_2(r) = \frac{\Delta^2\delta(r)}{\Delta^2/12} = 12\delta(r).$$

该首谐波形式是既有高斯量化矩结果的特例 [3], [4], [5]。第 V、VI 节在本文的条件相位记号下重新推导, 用于统一符号并给出完整级数与初等余项界; 第 VII 节再按本文的归一和容差反解阈值。作为无量纲核对, $r = 0.5$ 时 $\delta = 7.9206 \times 10^{-3}$, 故实际半幅为 $7.9206 \times 10^{-3}\Delta^2$, 相对调制 $A_2 = 9.5047\%$; 要求 $A_2 \leq 1\%$ 得首谐波阈值 $r = 0.619830$ 。完整级数的余项控制见第 VI、VII 节。

以直接 Q_4 的步长为单位, 令 $r = \sigma/4$ 。直接 Q_1 与直接 Q_4 的相位平均误差能量分别为 $r^2 + 1/192$ 与 $r^2 + 1/12$, 故目标 SNR 趋于零时的 DR 损失只依赖 r :

$$\Delta\text{DR}_{Q_4/Q_1}^{(T \rightarrow 0)}(r) = \frac{1}{2} \log_2 \frac{r^2 + 1/12}{r^2 + 1/192}.$$

若 16-bit 整数码经截位或 half-up 降到 14-bit, 扣除固定码值偏移后沿用同一相位平均能量; ties-to-even 的附加量见第 VIII 节。

B. 任意目标 SNR 下的 DR

设信号电子数为 S 、总读出等效噪声为 ν (电子单位, 散粒噪声方差取 S), 则

$$\text{SNR} = \frac{S}{\sqrt{S + \nu^2}}.$$

给定目标 SNR T , 令 $S/\sqrt{S + \nu^2} = T$, 平方后得 $S^2 - T^2S - T^2\nu^2 = 0$, 取正根

$$S_T(\nu) = \frac{T^2 + \sqrt{T^4 + 4T^2\nu^2}}{2}. \quad (2)$$

若满阱电子数为 F , 则该目标下的 SNR-based DR 为

$$\text{DR}(T; \nu, F) = \log_2 \frac{F}{S_T(\nu)}.$$

若两条链路的总等效噪声分别为 ν_a, ν_b , 并取相同满阱, 则链路 b 达到同一目标 SNR 相对链路 a 所损失的 DR 为

$$\Delta\text{DR}_{b/a}(T) = \log_2 \left(\frac{S_T(\nu_b)}{S_T(\nu_a)} \right).$$

其中量化项采用相位平均误差能量, 逐相位起伏由第 V、VI 节的条件矩给出。

IV. 量化相位结构与条带风险

A. 决定比值 $r = \sigma/\Delta$

条带 (banding) 风险由量化步长 Δ 、净时间噪声标准差 σ_t 、空间渐变斜率、显示映射和观察尺度一起决定。对本文的直接量化模型, 核心无量纲比值是 $r = \sigma_t/\Delta$ 。 r 很小时, 输入在量化阈值附近缺少随机抖动, 平滑渐变会和量化网格相干; 随着 r 增大, 量化相位逐渐被打散, 一阶均值结构按 $e^{-2\pi^2 r^2}$ 迅速衰减 (第 V 节)。这一相机语境下的经验建议见 [7], 专利中的相关工程规则见 [8]。第 VII 节给出直接量化的首谐波阈值及完整级数余项, 第 VIII 节给出 ties-to-even 的稳定阈值。

由光子转移特性可知, 同一位深下量化步长 Δ 不随信号改变。令 m 为以 DN 表示的平均信号电平, K 为电子数每 DN 的转换增益; 在把散粒噪声近似为高斯

项时, 量化前时间噪声 $\sigma_t(m) = \sqrt{\sigma_{\text{read}}^2 + m/K}$ 随信号上升 [12], 故 $r = \sigma_t/\Delta$ 在低码值处最小、向亮部增大。

第 VII 节定义的直接量化首谐波指标 A_1 与 A_2 都只依赖 r 。其绝对幅度另带标度因子: 一阶首谐波幅度为 ΔA_1 , 二阶首谐波半幅为 $(\Delta^2/12)A_2$ 。同一位深内 Δ 固定, 随信号变化的部分全部来自 $A_1(r)$ 、 $A_2(r)$; Δ 与 Δ^2 仅影响跨位深比较。

这些统计量刻画量化相位结构, 其可见性还受显示映射和观察条件影响。线性提亮对信号、时间噪声与量化步长同步缩放, 不改变 σ_t/Δ 。首谐波 A_1 随 r 严格下降; 首谐波 A_2 在 $0 < r < 1/(2\pi)$ 先上升、此后才下降。在 $r \geq 1/(2\pi)$ 的区间, 二者均随 r 增大而衰减。

B. 有限码域与非高斯噪声

本文的闭式和阈值以 $N \sim \mathcal{N}(0, \sigma^2)$ 、 $\sigma > 0$ 为前提, 并把量化器定义在无过载的无限均匀重建格点上。有限码域只有在评价区间远离上下端点、端点裁切概率可忽略时才沿用这些周期结论; 饱和或黑、白端点裁切会破坏平移周期性, 须按实际有限映射另算。对一般加性噪声, 一阶相位谐波由格点 $\varphi_N(2\pi k/\Delta)$ 控制, 二阶项还含 $\varphi'_N(2\pi k/\Delta)$; 故方差 $\text{Var}(N)$ 或由单个频率反解的等效高斯宽度都不足以替代完整分布。仅当噪声对称、目标格点上的 φ_N 为正且可微时, 才可分别定义

$$\sigma_{\text{damp}}^2(\omega) = -\frac{2 \ln \varphi_N(\omega)}{\omega^2}, \quad \sigma_{\text{cross}}^2(\omega) = -\frac{\varphi'_N(\omega)}{\omega \varphi_N(\omega)};$$

二者对高斯噪声恒等于 σ^2 , 对一般分布则随频率变化且不必相等。

总方差不足以确定一般噪声与同方差高斯模型之间的次序。即使噪声零均值、对称且方差有限, 其格点特征函数与导数仍会随离散质量、均匀分量或长尾混合而增大、减小或变号; 把总读噪均方根 (root mean square, RMS) 代入高斯式, 可能高估也可能低估一阶或二阶相位结构。一个等方差反例可直接说明这一点: 若 U_1, U_2 独立且均匀分布于 $[-\Delta/2, \Delta/2]$, 则 $N = U_1 + U_2$ 的方差为 $\Delta^2/6$, 并在所有非零格点上满足 $\varphi_N(\omega_k) = \varphi'_N(\omega_k) = 0$, 故两种相位半极差均为零; 而取 $P(N = \Delta) = P(N = -\Delta) = 1/12$ 、 $P(N = 0) = 5/6$ 时方差仍为 $\Delta^2/6$, 却有 $\varphi_N(\omega_k) = 1$ 、 $\varphi'_N(\omega_k) = 0$, 保留完整的格点相干结构。取 $\Delta = 1$ 时, 同方差高斯的 $\mathcal{A}[B]$ 和 $\mathcal{A}[M_2]$ 分别约为 0.01186 和 0.02861, 位于上述两例的 0, 0 与 1/2, 1/8 之间。相同方差下不存在统一的上下界关系。

若额外限定为中心高斯尺度混合 $N = \sqrt{V}Z$, 其中 $Z \sim \mathcal{N}(0, 1)$ 、 $V \geq 0$ 、 V 与 Z 独立且 $\mathbb{E}V = \sigma^2$, Jensen 不等式给出

$$\varphi_N(\omega) = \mathbb{E}e^{-\omega^2 V/2} \geq e^{-\omega^2 \sigma^2/2}.$$

同方差高斯由此低估每个一阶谐波系数的模。完整相位半极差由全部谐波合成。二阶正频率系数中的径向因子可写为

$$\mathbb{E}[(h_k + 2V)e^{-a_k V}], \quad a_k = \omega_k^2/2.$$

被积函数关于 V 的二阶导数为 $a_k e^{-a_k V} (2a_k V - 3)$, 其符号随 V 改变, 二阶系数的次序因而需要逐项计算。

在重复测量满足独立同分布条件时, 帧差可直接给出分布无关的必要条件。设 N_1, N_2 独立同分布, $D = N_1 - N_2$, 并记

$$\psi_D(\omega) = \mathbb{E}e^{i\omega D}, \quad \omega_k = \frac{2\pi k}{\Delta},$$

$$p_k = \psi_D(\omega_k), \quad q_k = \psi'_D(\omega_k).$$

则 $p_k = |\varphi_N(\omega_k)|^2 \geq 0$, 且 $q_k = 2 \text{Re}\{\varphi'_N(\omega_k) \overline{\varphi_N(\omega_k)}\}$ 。令

$$h_k = \frac{\Delta^2}{2\pi^2 k^2}, \quad b_k = \frac{\Delta}{\pi k},$$

$$m_k = \begin{cases} |h_k p_k - b_k q_k/2|/\sqrt{p_k}, & p_k > 0, \\ 0, & p_k = 0. \end{cases}$$

对周期实函数仍用半极差 $\mathcal{A}[f] = [\sup_s f(s) - \inf_s f(s)]/2$ 。

命题 1 (独立帧差给出的相位半极差下界): 设目标量化器为无过载的最近邻 Q_Δ , 量化前扰动 N_1, N_2 独立同分布、与确定性输入 s 独立且具有有限二阶矩, 所用特征函数可微。对任意有限非空正整数集 $\mathcal{K}$,

$$\mathcal{A}[B] \geq \max \left\{ \max_{k \in \mathcal{K}} \frac{\Delta \sqrt{p_k}}{4k}, \quad \frac{\Delta}{\sqrt{2}\pi} \left(\sum_{k \in \mathcal{K}} \frac{p_k}{k^2} \right)^{1/2} \right\},$$

$$\mathcal{A}[M_2] \geq \max \left\{ \frac{\pi}{2} \max_{k \in \mathcal{K}} m_k, \quad \left(2 \sum_{k \in \mathcal{K}} m_k^2 \right)^{1/2} \right\}. \quad (3)$$

证明只需比较傅里叶系数。直接量化的正频率系数满足

$$C_k^B = \frac{(-1)^k \Delta}{2\pi i k} \varphi_N(\omega_k),$$

$$C_k^M = (-1)^k \{h_k \varphi_N(\omega_k) - b_k \varphi'_N(\omega_k)\}.$$

帧差确定 $|C_k^B|$, 并把 $|C_k^M|$ 至少界为 m_k 。任意值域半宽为 $\mathcal{A}$ 的实周期函数满足 $|C_k| \leq 2\mathcal{A}/\pi$; Parseval 恒等

式和 Popoviciu 方差界又给出 $\mathcal{A}^2 \geq 2 \sum_{k>0} |C_k|^2$, 合并即得式 (3)。样本估计可用

$$\hat{p}_k = \frac{1}{n} \sum_j \cos(\omega_k D_j), \quad \hat{q}_k = -\frac{1}{n} \sum_j D_j \sin(\omega_k D_j),$$

有限样本下界应在 p_k, q_k 的同时置信域内取最不利值, 并以空间块和帧对作为聚类层。

1) *GFX100* 暗场检验: RAF 记录的是基准模数转换器 (analog-to-digital converter, ADC) 量化后的整数码。记两帧同一像素的码值为 Z_1, Z_2 , 观测差分为 $\hat{D} = Z_1 - Z_2$, 其特征函数为 $\psi_{\hat{D}}(\omega) = \mathbb{E}e^{i\omega\hat{D}}$ 。图 1 给出四帧 Fujifilm GFX100 ISO 100 机械快门无压缩暗场的检验结果; 文件哈希和重算命令归档在随稿 `data/gfx100_provenance.md`。中心 512×512 区域按四个彩色滤波阵列 (color filter array, CFA) 相位计算 $\text{std}(A - B)/\sqrt{2}$, 两对帧的单帧 RMS 分别为 5.026–5.176 和 5.058–5.193 DN16; 迭代 3.5σ 裁尾后降为 4.166–4.312 和 4.158–4.319 DN16, 两对共八个 CFA 相位的差分超额峰度为 14.535–18.721。少量尾部样本因平方权重显著抬高总 RMS。

整幅图按有效成像区坐标的 (row mod 18, col mod 6) 分层后, 在 $\omega = \pi/2$ 处两对帧均有相同五个格点满足 $|\psi_{\hat{D}}| = 0.993\text{--}0.995$, 其余格点不超过 0.049; 两对 18×6 格点的相关系数为 0.999995, 五个分散空间块的最低相关系数为 0.99735。整数 RAW 的码值差分统计具有可复测的空间相位异质性, 全幅合并会混合 18×6 个不同层。

$\psi_{\hat{D}}$ 描述 ADC 后码值差分, 命题 1 中的 ψ_D 描述 ADC 前读噪差分。四帧数据给出量化后码值差分的重尾和空间相位异质性; 命题中的 p_k, q_k 则应从带有基准 ADC 映射的独立帧差估计。具体可采用独立标定的固定坏点掩膜、稳定线性感兴趣区 (region of interest, ROI)、 18×6 相位与空间块分层, 以及以独立帧对为外层聚类的同时置信区间; 帧数由预设置信水平、目标区间宽度和有效独立样本数确定。

完整评价还应核查噪声的加性、平稳性、独立性和空间分层, 确认预处理符合所用标量链模型。空间相关噪声、DSNU、行列噪声和黑电平校正残差可结合协方差、二维功率谱和重复帧固定图样分解描述; 一般非高斯链路则可估计各目标频率上的 φ_N, φ'_N , 或直接测量 $B(s)$ 与 $M_2(s)$ 。显示侧再结合编码曲线、gamma、查找表和观察条件评价可见性 [28], [29], [30], [31], [32]。由此形成条件矩估计和显示可见性分析两个环节。

V. 一阶条件均值偏差: 确定性均值结构

A. 模型及期望

设量化前 $X = s + N$, $N \sim \mathcal{N}(0, \sigma^2)$ 且 $\sigma > 0$, 直接量化输出 $Y^{\text{dir}} = Q_{\Delta}(X)$, 误差 $e = Y^{\text{dir}} - s$ 。固定 s 反复拍、在独立同分布时间读噪的假设下做无限平均:

$$\lim_{n \rightarrow \infty} \frac{1}{n} \sum_{i=1}^n Q_{\Delta}(s + N_i) = \mathbb{E}[Q_{\Delta}(s + N) | s].$$

无限堆栈的极限保留条件均值偏差

$$B_{\Delta}(s) = \mathbb{E}[Q_{\Delta}(s + N) | s] - s.$$

如果 $B_{\Delta}(s)$ 随 $s \bmod \Delta$ 周期变化, 就有确定性的均值相位结构; 如果 $B_{\Delta}(s)$ 的幅度低于给定测量容差, 则在该容差内没有可分辨的均值相位结构。本节闭式对应直接 $Q_{\Delta}(s + N)$, 也给出中心化截位与 half-up 的同幅相移波形; ties-to-even 两级链路的极限偏差见第 VIII 节。

B. 闭式傅里叶级数

最近邻量化残差 $q(u) = \text{round}(u) - u$ 是周期函数。在非跳点其锯齿展开为

$$q(u) = \sum_{k=1}^{\infty} \frac{(-1)^k}{\pi k} \sin(2\pi k u).$$

在半整数跳点, 傅里叶级数取左右极限的中值。以下取 $\sigma > 0$, 跳点的 tie 规则不影响卷积结果。由于 $q \in L^2(\mathbb{T})$, 其与周期化高斯核的卷积是光滑函数; 由周期卷积的傅里叶定理 (等价地, 由 L^2 配对和热核正则化), 卷积系数逐项乘以 $\Phi_N(2\pi k/\Delta) = \exp(-2\pi^2 k^2 r^2)$, 所得级数绝对且一致收敛。于是

$$B_{\Delta}(s) = \frac{\Delta}{\pi} \sum_{k=1}^{\infty} \frac{(-1)^k}{k} \exp\left[-2\pi^2 k^2 \left(\frac{\sigma}{\Delta}\right)^2\right] \sin\left(2\pi k \frac{s}{\Delta}\right). \quad (4)$$

$\sin(2\pi k s/\Delta)$ 是量化相位的周期结构, 指数项表示高斯读噪对该结构的衰减。

C. 严格上界、截断余项与阈值稳定性

记首谐波项为

$$B_{\Delta,1}(s) = -\frac{\Delta}{\pi} e^{-2\pi^2 r^2} \sin\left(2\pi \frac{s}{\Delta}\right).$$

对完整级数使用 $1/k \leq 1$ 和 $k^2 \geq 1 + 3(k-1)$, 得到

$$|B_{\Delta}(s)| \leq \frac{\Delta}{\pi} \sum_{k \geq 1} \frac{1}{k} e^{-2\pi^2 k^2 r^2} \leq \frac{\Delta}{\pi} \frac{e^{-2\pi^2 r^2}}{1 - e^{-6\pi^2 r^2}}.$$




图 1. GFX100 四帧暗场检验。(a) 圆点为未裁尾的 $\text{std}(A - B)/\sqrt{2}$, 三角为迭代 3.5σ 裁尾后的同一尺度, 阴影为独立光子转移曲线 (photon transfer curve, PTC) 拟合的读噪截距范围; (b) 横轴以差分绝对残差相对由中位数绝对偏差 (median absolute deviation, MAD) 换算的稳健尺度归一, 竖点线标出 3.5σ 裁尾位置, 两对帧的尾部均显著偏离高斯参考; (c) $\omega = \pi/2$ 处 18×6 相位格的 $|\psi_D|$, 实线轮廓标出 $|\psi_D| > 0.9$; (d) 两对帧在全部相位格上的复测。原始 RAF 的 SHA-256、派生表和重算命令见随稿设备检验说明。

该式给出总幅度的严格上界。对于截断余项 $R_{B,1} = B_\Delta - B_{\Delta,1}$, 由 $1/k \leq 1/2$ 和 $k^2 \geq 4 + 5(k-2)$ ($k \geq 2$) 进一步得到

$$|R_{B,1}(s)| \leq \frac{\Delta}{2\pi} \frac{e^{-8\pi^2 r^2}}{1 - e^{-10\pi^2 r^2}}.$$

与首谐波幅值相比,

$$\frac{\sup_s |R_{B,1}(s)|}{(\Delta/\pi)e^{-2\pi^2 r^2}} \leq \frac{e^{-6\pi^2 r^2}}{2(1 - e^{-10\pi^2 r^2})} \leq 3.84 \times 10^{-5}.$$

可见在 $r \geq 0.4$ 的阈值区间, 首谐波近似的相对截断误差低于 3.84×10^{-5} 。

把细量化写成 Q_1 、粗量化写成 Q_4 , 并令 $r = \sigma/4$ 。定义按粗步长归一的期望差 $b_D(s) = [B_4(s) - B_1(s)]/4$ 。由三角不等式和上述完整级数界,

$$\begin{aligned} \frac{\sup_s |B_4(s)|}{4} &\leq u_4(r) := \frac{1}{\pi} \frac{e^{-2\pi^2 r^2}}{1 - e^{-6\pi^2 r^2}}, \\ |b_D(s)| &\leq u_D(r) := u_4(r) + \frac{1}{4\pi} \frac{e^{-32\pi^2 r^2}}{1 - e^{-96\pi^2 r^2}}. \end{aligned} \quad (5)$$

u_4 控制直接 Q_4 的绝对条件偏置, u_D 控制 Q_4 与 Q_1 的条件均值差; 两式均为完整级数的上界。在 $\varepsilon = 1\%$ 时, 方程 $u_4(r) = \varepsilon$ 的唯一根为 $r = 0.418700$ 。此时 u_D 中的 Q_1 项为 7.2×10^{-26} , 故两个阈值在本文列示精度内相同。若只保留主导的 Q_4 首谐波, 近似阈值为

$$r_1(\varepsilon) = \sqrt{\frac{\ln[1/(\pi\varepsilon)]}{2\pi^2}},$$

即第 VII 节直接量化的一阶阈值。 $r \geq 0.4$ 时, 前述余项界保证首谐波近似与严格上界的差异很小; 表 IV 的直接一阶列计算 u_4 , 跨位深差值则计算 u_D 。中心化截位与 half-up 只改变相位原点, 沿用同一幅度界; ties-to-even 两级链路采用第 VIII 节的离散模型。

VI. 二阶矩分布

即使一阶均值偏差为零, 误差分布仍可能具有随输入变化的方差、尾部、偏斜、峰度和空间相关性。对低

阶量化相位结构来说，第二个最基础的量是二阶误差能量 $M_{2,\Delta}(s) = \mathbb{E}[(Y - s)^2 | s]$ 。

A. 三项分解

归一化 $\theta = s/\Delta$, $r = \sigma/\Delta$, $Z = N/\Delta \sim \mathcal{N}(0, r^2)$, 归一化总误差 $\eta_\theta = (Y - s)/\Delta = \text{round}(\theta + Z) - \theta = Z + q(\theta + Z)$ 。于是

$$M_2(\theta) = \mathbb{E}[\eta_\theta^2] = \underbrace{\mathbb{E}[Z^2]}_{\text{读噪能量}} + \underbrace{2\mathbb{E}[Zq(\theta + Z)]}_{\text{交叉项}} + \underbrace{\mathbb{E}[q(\theta + Z)^2]}_{\text{量化残差能量}}.$$

该分解若直接写成读噪方差加 $\Delta^2/12$, 便默认交叉项与相位项可以略去; 这在 SNR-based DR 的均匀量化噪声近似中通常足够, 但在二阶相位分析中需要显式保留这些项 (见 VI-C 节)。

B. 傅里叶闭式

量化残差平方的周期展开为

$$q(u)^2 = \frac{1}{12} + \sum_{k=1}^{\infty} \frac{(-1)^k}{\pi^2 k^2} \cos(2\pi k u).$$

两个高斯期望 (第二个可由 Stein 引理 $\mathbb{E}[Zg(Z)] = r^2 \mathbb{E}[g'(Z)]$ 得到)

$$\mathbb{E}[\cos(2\pi k(\theta + Z))] = e^{-2\pi^2 k^2 r^2} \cos(2\pi k \theta),$$

$$\mathbb{E}[Z \sin(2\pi k(\theta + Z))] = 2\pi k r^2 e^{-2\pi^2 k^2 r^2} \cos(2\pi k \theta).$$

将 $q, q^2 \in L^2(\mathbb{T})$ 与周期化高斯核作卷积, 并对该光滑卷积求导处理交叉项; 周期卷积的傅里叶定理使各系数乘上高斯阻尼, 所得级数绝对且一致收敛。代回三项分解得到

$$M_2(\theta) = r^2 + \frac{1}{12} + \sum_{k=1}^{\infty} (-1)^k \left(4r^2 + \frac{1}{\pi^2 k^2} \right) e^{-2\pi^2 k^2 r^2} \cos(2\pi k \theta). \quad (6)$$

乘回 DN16 单位即 $\mathbb{E}[(Q_\Delta(s + N) - s)^2 | s] = \Delta^2 M_2(s/\Delta)$ 。 $r \rightarrow 0$ 时 $M_2 \rightarrow q(\theta)^2$ (纯量化误差), $r \rightarrow \infty$ 时 $M_2 \rightarrow r^2 + \frac{1}{12}$, 趋近均匀量化噪声近似。

C. 截断余项、量级与交叉项

记只保留 $k = 1$ 的二阶近似为

$$M_{2,1}(\theta) = r^2 + \frac{1}{12} - \left(4r^2 + \frac{1}{\pi^2} \right) e^{-2\pi^2 r^2} \cos(2\pi \theta).$$

对余项 $R_{M,1} = M_2 - M_{2,1}$, 利用 $k \geq 2$ 时 $1/k^2 \leq 1/4$ 及 $k^2 \geq 4 + 5(k - 2)$, 得到

$$|R_{M,1}(\theta)| \leq \left(4r^2 + \frac{1}{4\pi^2} \right) \frac{e^{-8\pi^2 r^2}}{1 - e^{-10\pi^2 r^2}}.$$

在 $r \geq 0.4$ 时, 该余项与二阶首谐波幅值之比不超过 7.68×10^{-5} ; 此处将系数比保守地放宽到 1。乘回实际单位后, 余项上界还需乘 Δ^2 。

命题 2 (直接量化的充分条件): 在式 (1) 的直接链路中, 设 $N \sim \mathcal{N}(0, \sigma^2)$ 、 $\sigma > 0$, N 与确定性输入 s 独立, 并采用最近邻标量量化。则式 (4) 与式 (6) 绝对收敛。若式 (5) 满足 $u_4(r) \leq \varepsilon$, 则 $\sup_s |B_4(s)|/4 \leq \varepsilon$; 若 $u_D(r) \leq \varepsilon$, 则 $\sup_s |B_4(s) - B_1(s)|/4 \leq \varepsilon$ 。二阶首谐波与 $R_{M,1}$ 上界之和控制完整二阶相位幅度。

阈值区域的二阶近似必须保留交叉项。在 $r = 0.5$ 处, 舍去交叉项会使首谐波系数减少 $4r^2 e^{-2\pi^2 r^2} = 0.0071919$, 对应 $0.0071919\Delta^2$ 的最坏相位误差; 同一点截去全部 $k \geq 2$ 谐波的误差上界仅为 $2.7431 \times 10^{-9}\Delta^2$ 。两者相差六个数量级。二阶近似应保留读噪交叉项, 而高次谐波可在余项界控制下截断。

VII. 一阶与二阶量化痕迹的容差阈值

在本文的直接均匀量化模型内, 读噪是否足以打散量化痕迹由相对读噪 $r = \sigma/\Delta$ 决定; 同一组无量纲指标适用于任意位深和量化步长。改变输出位深会改变 Δ , 指数衰减项则由比值 σ/Δ 决定。

对一阶条件均值, 首谐波的无量纲幅度为

$$A_1(r) = \frac{1}{\pi} \exp(-2\pi^2 r^2),$$

该指标度量量化误差均值随输入相位起伏的首谐波强度。这个量若仍然较大, 误差均值便含有空间相干结构, 平均、堆栈或局部积分之后仍可能留下稳定的等级边界。完整偏置与该指标之间的误差由 V-C 节的余项界控制 (图 2)。

对二阶误差能量, 首谐波的归一化幅度为

$$A_2(r) = 12 \left(4r^2 + \frac{1}{\pi^2} \right) \exp(-2\pi^2 r^2),$$

该量刻画误差二阶矩随输入相位起伏的强度, 并以均匀量化误差方差 $\Delta^2/12$ 归一; 实际主相位半幅为 $(\Delta^2/12)A_2(r)$ 。对直接量化, M_2 在完整周期上的相位平均恒为 $\sigma^2 + \Delta^2/12$, 故 $A_2 = \varepsilon$ 表示二阶相位半幅与均匀量化误差方差之比为 ε 。这里的 ε 为模型容差, 相




图 2. 直接量化的一阶、二阶首谐波幅度随相对读噪 $r = \sigma/\Delta$ 的衰减。实线为按 Δ 归一的 A_1 ，虚线为按 $\Delta^2/12$ 归一的 A_2 ；水平参考线依次为 1%、0.1% 与 0.01%。颜色与线型重复编码，黑白打印时仍可区分。

机参数的估计误差由测量过程确定。给定统一容差，直接量化的首谐波阈值由 $A_1(r) = \varepsilon$ 与 $A_2(r) = \varepsilon$ 确定：

$$r_{1,\varepsilon} = \sqrt{\frac{\ln[1/(\pi\varepsilon)]}{2\pi^2}},$$

$$r_{2,\varepsilon} = \frac{1}{2\pi} \sqrt{-2W_{-1}\left(-\frac{\pi^2\varepsilon}{24\sqrt{e}}\right) - 1}.$$

其中 W_{-1} 为 Lambert W 函数的 -1 分支。取 $\varepsilon = 1\%$ ，得到 $r_{1,\varepsilon} = 0.418698$ 、 $r_{2,\varepsilon} = 0.619830$ 。在这两个阈值处，一阶偏置余项不超过 $1.551 \times 10^{-7}\Delta$ ，二阶余项相对于 $\Delta^2/12$ 不超过 1.256×10^{-12} ；完整级数与首谐波阈值在本文列示精度内一致。 $r = 0.5$ 与 $r = 0.75$ 两处的相位波形分别见图 3、图 4。容差收紧到 0.1% 时，两者分别为 0.540 与 0.718；收紧到 0.01% 时分别为 0.639 与 0.801。

把上述解析首谐波阈值取一位小数，可得到表 II 所示的直接量化模型容差分区。

VIII. ties-to-even 两级量化

A. ties-to-even 的两级量化模型

本节研究一个完全指定的映射：先作步长为 1 的均匀量化，再把整数码按步长 4 作 ties-to-even 再量化。本文借用 IEEE 754 的 roundTiesToEven 规则定义该整数映射 [20]；该规则也称 convergent rounding，在中点处依输出码奇偶选择方向，因而不满足通常把再量化视为一次平移均匀量化的前提 [4]。直接枚举即可验证：输出 0 并入 $n \in \{-2, \dots, 2\}$ ，输出 4 并入 $n \in \{3, 4, 5\}$ ，故有效单元宽度为 5, 3 交替，而非恒为 4。

令 $\sigma > 0$ 、 $n = Q_1(s + N) \in \mathbb{Z}$ ，并定义

$$p_n(s) = \Phi_G\left(\frac{n + 1/2 - s}{\sigma}\right) - \Phi_G\left(\frac{n - 1/2 - s}{\sigma}\right), \quad (7)$$

$$T(n) = 4 \text{round}_{\text{even}}(n/4),$$

其中 Φ_G 为标准正态分布函数。两级模型的条件均值偏差和二阶误差能量可直接求和：

$$B_{\text{post}}(s) = \sum_{n \in \mathbb{Z}} T(n) p_n(s) - s,$$

$$M_{2,\text{post}}(s) = \sum_{n \in \mathbb{Z}} [T(n) - s]^2 p_n(s). \quad (8)$$

式 (7) 与式 (8) 给出的两个条件矩都是以 8 为周期的连续函数，且仅依赖无量纲比值 $r = \sigma/4$ 。后文的阈值由该离散和计算，参数为 r 。当 $\sigma = 0$ 时，应直接使用确定性复合映射 $T(Q_1(s))$ ，并在阈值点按明示的 tie 规则取值；上述正态分布函数表达式适用于 $\sigma > 0$ 。

1) 截位、普通四舍五入与 ties-to-even: 对非负 RAW 整数码 n ，三种转移规则为

$$T_{\text{floor}}(n) = 4\lfloor n/4 \rfloor, \quad T_{\text{half-up}}(n) = 4\lfloor n/4 + 1/2 \rfloor,$$

$$T_{\text{even}}(n) = 4 \text{round}_{\text{even}}(n/4).$$

对每条链路加入表 III 中的固定码值校正 c ，定义其相对连续含噪输入的完整误差函数 $g_T(x) = T(Q_1(x)) + c - x$ 。一个周期内的有效量化单元也列于该表，横线表示对该完整周期的均匀平均。

截位和 half-up 校正后都是单元宽度为 4、重建值位于单元中心的均匀量化器，只与直接 Q_4 相差网格相位。因此二者的一阶、二阶条件矩波形只发生横向平移，第 VII 节的幅度阈值和第 III 节的 DR 表达式无需重算。ties-to-even 则形成宽度 5, 3 交替的单元，无法用固定偏移化为均匀 Q_4 ；其相位平均量化误差能量为 19/12，比中心化均匀宽度 4 的 16/12 多 1/4。固定相位下仍必须使用上面的离散和。

B. 两级模型的相位结构、主导区与 DR 行为

1) 与直接量化一致的阈值口径：把第 VII 节的阈值口径用于两级离散转移模型。令 $r = \sigma/\Delta_{14}$ ，并在一个完整的 $s \bmod 8$ 周期内取最大相位幅度，定义

$$A_{1,\text{post}}(r) = \frac{\max_s |B_{\text{post}}(s)|}{\Delta_{14}},$$

$$A_{2,\text{post}}(r) = \frac{\frac{1}{2}[\max_s M_{2,\text{post}}(s) - \min_s M_{2,\text{post}}(s)]}{\Delta_{14}^2/12}.$$




图 3. 在 $r = 0.5$ 下的完整相位级数。实线为 $B_{\Delta}(s)/\Delta$ ，虚线为 $M_2(s)/\Delta^2 - (r^2 + 1/12)$ ；横轴为 s/Δ 。




图 4. 在 $r = 0.75$ 下的完整相位级数。实线为 $B_{\Delta}(s)/\Delta$ ，虚线为 $M_2(s)/\Delta^2 - (r^2 + 1/12)$ ；横轴为 s/Δ 。

表 II

直接量化的模型容差分区。 $r = \sigma/\Delta$ ； A_1 按 Δ 归一， A_2 按 $\Delta^2/12$ 归一；边界由第 VII 节首谐波解析指标取一位小数得到。

参数范围	低阶相位结构的量级解释
$r < 0.4$	一阶、二阶通常仍在 1% 量级或更高
$0.4 \leq r < 0.6$	一阶穿过 1% 阈值，二阶仍占主导
$0.6 \leq r < 0.7$	二阶穿过 1% 阈值，并向 0.1% 量级衰减
$0.7 \leq r < 0.8$	二阶由约 0.1% 向 0.01% 量级衰减
$r \geq 0.8$	一阶、二阶均约在 0.01% 量级或更低

表 III

三种转移规则的中心化误差统计

规则	校正 c (Q1 步长)	有效单元宽度	$\overline{g_T}$	$\overline{g_T^2}$ (Q1 步长平方)
截位	$+3/2$	均匀 4	0	16/12
half-up	$-1/2$	均匀 4	0	16/12
ties-to-even	0	5、3 交替	0	19/12

$A_1 \leq \varepsilon$ 与 $A_2 \leq \varepsilon$ 使用同一个无量纲相对容差。前者是条件均值偏置相对于一个量化步长的比例，后者是二阶误差能量相位调制相对于均匀量化误差方差 $\Delta_{14}^2/12$ 的比例。两级指标取完整离散和的相位极值。直接量化的首谐波解析指标 $A_{1,\text{dir}} = \pi^{-1}e^{-2\pi^2 r^2}$ 与 $A_{2,\text{dir}} = 12(4r^2 + \pi^{-2})e^{-2\pi^2 r^2}$ 用于说明机理；表 IV 的直接一阶列采用完整级数界 u_4 ，直接二阶列采用首谐波与解析余项之和。表中两条链路的一阶列均为相对理想信号的绝对条件偏置，二阶列均为相位半极差。

对任一指标 $A(r)$ ，稳定阈值定义为 $r_\varepsilon = \inf\{r : A(r') \leq \varepsilon, \forall r' \geq r\}$ 。为把映射定义留在首次出现处，把一般周期表推导集中在一处，本节先调用第 IX-B 节

随后证明的系数闭式与尾界。记其中两类非零谐波系数为 $C_{1,k}$ 、 $C_{2,k}$ ，并定义

$$\begin{aligned} \mathcal{U}_1(r) &= \frac{2}{\Delta_{14}} \sum_{k \geq 1} |C_{1,k}(r)|, \\ \mathcal{U}_2(r) &= \frac{2}{\Delta_{14}^2/12} \sum_{k \geq 1} |C_{2,k}(r)|. \end{aligned} \quad (9)$$

三角不等式给出 $A_{j,\text{post}}(r) \leq \mathcal{U}_j(r)$ 。对 ties-to-even，令 $\omega_k = \pi k/4$ 、 $c_k = \cos(3\omega_k/2)$ 、 $s_k = \sin(3\omega_k/2)$ ，第 IX-B 节闭式化为

$$\begin{aligned} |C_{1,k}| &= \frac{|c_k|}{\omega_k} e^{-8r^2 \omega_k^2}, \\ |C_{2,k}| &= \left| c_k \left(\frac{2}{\omega_k^2} + 32r^2 \right) - \frac{s_k}{\omega_k} \right| e^{-8r^2 \omega_k^2}. \end{aligned}$$

第一式的每个非零项都随 r 下降, 故 $\mathcal{U}_1$ 随 r 下降。对第二式逐项求导, 其所有正驻点均满足 $r^2 = [\omega_k^{-2} + \tan(3\omega_k/2)/(2\omega_k)]/16$; 按 $k \bmod 16$ 化简后, 最大的相关驻点在 $k = 1$, 为 $r = 0.444275$ 。故 $\mathcal{U}_2$ 在 $r \geq 1/2$ 也单调下降。于是

$$\bar{r}_{j,\varepsilon} = \inf\{r \geq 1/2 : \mathcal{U}_j(r) \leq \varepsilon\}$$

保证对一切 $r' \geq \bar{r}_{j,\varepsilon}$ 都有 $A_{j,\text{post}}(r') \leq \varepsilon$ 。

无限和由有限和与解析尾界计算。令 $D_1 = \Delta_{14}$ 、 $D_2 = \Delta_{14}^2/12$, 并以第 IX-B 节给出的两侧尾项解析上界 $\bar{R}_j(L)$ 定义

$$\tilde{\mathcal{U}}_j^{(L)}(r) = \frac{2 \sum_{k=1}^L |C_{j,k}(r)| + \bar{R}_j(L)}{D_j} \geq \mathcal{U}_j(r). \quad (10)$$

本文取 $L = 24$, 表中两级阈值取 $\tilde{\mathcal{U}}_j^{(24)} = \varepsilon$ 的上界根。在 1% 容差下, 两根为 0.804399 与 1.273439。直接离散高斯转移和在 4096、8192 与 16384 个相位上的极值根分别稳定在 0.804391 与 1.273439, 与表中三位小数一致。

命题 3 (*ties-to-even* 的容差阈值): 对式 (1) 的 *ties-to-even* 两级链路, 设 $N \sim \mathcal{N}(0, \sigma^2)$ 、 $\sigma > 0$, N 与确定性输入 s 独立, 且 $r \geq 1/2$ 。则式 (9) 的 $\mathcal{U}_1, \mathcal{U}_2$ 单调不减, 并分别控制一阶绝对偏差与二阶半极差。若式 (10) 不超过 ε , 则对一切更大的 r , 对应指标均不超过 ε 。

命题 2 与命题 3 的阈值汇总于表 IV。

约两倍的阻尼尺度来自基本周期扩展; 具体阈值由完整前因子和尾界决定。定义 $e_{\text{dir}}(x) = Q_4(x) - x$ 与 $e_{\text{post}}(x) = T(Q_1(x)) - x$, 两者的周期分别为 4 和 8 个 Q1 步长。

周期为 P 的函数经方差为 σ^2 的高斯卷积后, 第 k 个傅里叶分量带有阻尼

$$G_P(k) = \exp\left[-\frac{\sigma^2}{2} \left(\frac{2\pi k}{P}\right)^2\right].$$

对条件偏置有 $B(s) = \mathbb{E}[e(s+N)]$; 对二阶矩有 $M_2(s) = \sigma^2 + 2\mathbb{E}[Ne(s+N)] + \mathbb{E}[e^2(s+N)]$ 。高斯分部积分给出

$$\mathbb{E}[Ne(s+N)] = \sigma^2 \frac{d}{ds} \mathbb{E}[e(s+N)].$$

因此, M_2 的非零谐波也带有 $G_P(k)$, 交叉项只改变其多项式系数和相位。

取 $\sigma = 4r$, 两个基本频率的阻尼分别为

$$G_4(1) = e^{-2\pi^2 r^2}, \quad G_8(1) = e^{-\pi^2 r^2/2}.$$

指数中 r^2 的系数相差 4 倍, 达到相近衰减量所需的 r 因而约相差 $\sqrt{4} = 2$ 倍。表中间值的比值也接近 2。完整系数决定具体阈值, 其中二阶系数还包含交叉项。

2) 码值—像素阶梯与固定相位: 这里的信号相位是连续均值 s 相对量化网格的位置。直接 Q1 和直接 Q4 同样有相位依赖; 二者的 $B(s)$ 与 $M_2(s)$ 分别以 1 和 4 个 Q1 步长为周期。两级 *ties-to-even* 链路因粗码奇偶交替, 基本周期扩展到 8 个 Q1 步长; 三条无噪声阶梯见图 5。




图 5. 无噪声线性渐变的码值—像素阶梯。实线直接 Q1 每隔一个基准步长跳变; 虚线直接 Q4 的均匀单元宽 4; 点划线两级 Q4(Q1) *ties-to-even* 出现 3, 5 交替单元。图中读噪取零, 用于说明阈值与网格相位。

3) 相位平均均方误差 (*MSE*) 与目标 *SNR* 的 $T \rightarrow 0$ *DR* 极限: 固定信号相位下, Q1 误差、*ties-to-even* 映射和读噪通过同一个整数码耦合, $M_{2,\text{post}}(s)$ 始终由 VIII-A 节的离散和计算。本节再对均匀相位平均:

$$\overline{M_2} := \frac{1}{8} \int_0^8 M_2(s) ds.$$

定义完整等效量化误差 $g(x) = T_{\text{even}}(Q_1(x)) - x$, 则最终误差为 $e = N + g(s+N)$ 。 g 以 8 为周期; 一个周期内, 重建值 0 和 4 对应的单元分别为 $[-5/2, 5/2)$ 与 $[5/2, 11/2)$, 宽度为 5 和 3。故

$$\bar{g} = 0, \quad \overline{g^2} = \frac{1}{8} \left(\int_{-5/2}^{5/2} x^2 dx + \int_{5/2}^{11/2} x^2 dx \right) = \frac{19}{12}.$$

对任一固定噪声实现 $N = z$, 周期平移不改变上述积分, 因此

$$\frac{1}{8} \int_0^8 [z + g(s+z)]^2 ds = z^2 + \frac{19}{12}.$$

交叉项在这个周期积分下严格为零; 该结论不使用误差独立假设。再对 $N \sim \mathcal{N}(0, \sigma^2)$ 取期望, 得到

$$\overline{M_{2,\text{post}}} = \sigma^2 + \frac{19}{12} = \Delta_{14}^2 \left(r^2 + \frac{19}{192} \right). \quad (11)$$

表 IV

两级与直接量化的容差阈值。\$r = \sigma/\Delta_{14}\$；两条链路的一阶指标均为相对理想信号的最大绝对条件偏置，并按 \$\Delta_{14}\$ 归一，二阶指标均为按 \$\Delta_{14}^2/12\$ 归一的相位半极差。两级列使用 \$L = 24\$ 的解析尾包络，直接一阶列使用 \$u_4\$；所有阈值均向上取至三位小数。

相对容差 \$\epsilon\$	两级阈值（绝对一阶）	两级阈值（二阶半极差）	直接 Q4 阈值（绝对一阶）	直接 Q4 阈值（二阶半极差）
1%	0.805	1.274	0.419	0.620
0.1%	1.056	1.465	0.541	0.718
0.01%	1.258	1.630	0.640	0.802

作为比较，直接 Q1 与直接 Q4 的相位平均 MSE 分别为

$$\overline{M_{2,Q1}} = \Delta_{14}^2 \left(r^2 + \frac{1}{192} \right), \quad \overline{M_{2,Q4}} = \Delta_{14}^2 \left(r^2 + \frac{1}{12} \right).$$

以式 (11) 的 \$\sqrt{M_2}\$ 定义相位平均等效噪声，令目标 SNR 参数 \$T \rightarrow 0\$，得到代数 DR 极限

$$\begin{aligned} \Delta \text{DR}_{\text{post}/Q1}^{(T \rightarrow 0)} &= \frac{1}{2} \log_2 \frac{r^2 + 19/192}{r^2 + 1/192}, \\ \Delta \text{DR}_{Q4/Q1}^{(T \rightarrow 0)} &= \frac{1}{2} \log_2 \frac{r^2 + 1/12}{r^2 + 1/192}, \\ \Delta \text{DR}_{\text{post}/Q4}^{(T \rightarrow 0)} &= \frac{1}{2} \log_2 \frac{r^2 + 19/192}{r^2 + 1/12}. \end{aligned}$$

上述三条 \$T \rightarrow 0\$ 极限的参数关系见图 6。这里的 \$T\$ 是式 (2) 的目标 SNR 参数；有限码域黑端点见 IV-B 节。




图 6. 两级 Q4(Q1) ties-to-even 的相位平均 MSE 与目标 SNR 参数 \$T \rightarrow 0\$ 时的 DR 极限。实线为两级链路相对直接 Q1 的总代价，虚线为直接 Q4 相对直接 Q1，点线为两级链路相对直接 Q4 的 tie 附加量；横、纵轴均为对数尺度。

相位平均 \$T \rightarrow 0\$ DR 极限可在一阶、二阶相位调制已经很低时继续存在，因为前者取决于平均 MSE，后两者计量随 \$s\$ 周期变化的相干部分。上面三个式子给出

任意 \$r\$ 下的完整参数关系，固定相位的 \$M_2(s)\$ 则由离散和计算。

IX. 压扩曲线与压扩表的相位结构

第 VIII 节处理一条确定的两级舍入规则，本节把同一方法推广到周期压扩表。本节沿用第 II 节规定的独立同分布高斯模型；\$G\$ 表示最小周期内的组数，\$P\$ 表示该周期覆盖的输入码数。周期结构影响条件矩的事实与整数步长压扩的既有分析一致 [9], [11], [19], [12]；本文进一步给出精确的傅里叶系数及其解析尾界。

A. 由局部比值反推连续压扩曲线

设量化前的局部噪声标准差为正函数 \$\sigma_t(m)\$。若要求全码值域满足 \$\sigma_t(m)/\Delta(m) \geq r^*\$，则码值分配函数必须满足

$$c(m) = \int_0^m \frac{dm'}{\Delta(m')} \geq r^* \int_0^m \frac{dm'}{\sigma_t(m')}.$$

取等号给出在该点态约束下码数最少的连续曲线。若 \$\sigma_t^2(m) = \sigma_0^2 + m/K\$，则

$$c(m) = 2Kr^* \left(\sqrt{\sigma_0^2 + \frac{m}{K}} - \sigma_0 \right), \quad \frac{dc}{dm} \sigma_t(m) = r^*.$$

该仿射方差模型直接给出平方根形状。对有限满量程 \$F\$，\$[c(F)]\$ 是连续设计所需输出间隔数的下界。整数化还会引入重复单元与段间边界，下一小节据此转向完整周期表分析。上述构造与按噪声位数分配码值的经典结果相同 [9], [33], [34]；本文将其与条件矩指标联系起来。

B. 周期表的精确谐波与严格上界

令 \$a_0 = 0\$、\$a_{i+1} = a_i + w_i\$，\$w_i \in \mathbb{N}_+\$，并定义 \$T(n) = R_i\$ 对 \$n \in \{a_i, \dots, a_{i+1} - 1\}\$ 成立。周期延拓满足 \$T(n + P) = T(n) + P\$，其中 \$P = \sum_{i=0}^{G-1} w_i\$ 为最小周期。记组中心 \$c_i = (a_i + a_{i+1} - 1)/2\$、重建偏移 \$d_i = R_i - c_i\$，并令复合误差 \$g(x) = T(Q_1(x)) - x\$。输入坐标、判决边界和重建值共同平移只改变相位原点；

单独给全部 R_i 加常量会改变误差的直流分量, 属于另一种变换。

一个周期上的直流偏置为

$$\bar{B} = \hat{g}_0 = \frac{1}{P} \int_0^P g(x) dx = \frac{1}{P} \sum_i w_i d_i. \quad (12)$$

周期卷积不改变直流项, 故加性噪声下的条件均值同样以 $\bar{B}$ 为周期平均。

在一个周期内, 记判决边界为 e_i 、跳变为 $J_i = R_{i+1} - R_i$, 并定义 $\alpha_i = e_i - R_i$ 、 $\beta_i = R_{i+1} - e_i$ 与 $\omega_k = 2\pi k/P$ 。对 $k \neq 0$ 分部积分得到

$$\begin{aligned} \hat{g}_k &= \frac{1}{i\omega_k P} \sum_i J_i e^{-i\omega_k e_i}, \\ \hat{g}_k^2 &= \frac{1}{P} \sum_i e^{-i\omega_k e_i} \left[\frac{2J_i}{\omega_k^2} + i \frac{\alpha_i^2 - \beta_i^2}{\omega_k} \right]. \end{aligned} \quad (13)$$

若 $N \sim \mathcal{N}(0, \sigma^2)$, 则条件均值与条件二阶矩的非直流系数分别为

$$\begin{aligned} C_{1,k} &= \hat{g}_k e^{-\sigma^2 \omega_k^2 / 2}, \\ C_{2,k} &= \left(\hat{g}_k^2 + 2i\sigma^2 \omega_k \hat{g}_k \right) e^{-\sigma^2 \omega_k^2 / 2}. \end{aligned} \quad (14)$$

第二式中的交叉项来自 $2\mathbb{E}[Ng(s+N)]$, 需与第一式的阻尼同时保留。周期 P 决定频率网格, 并通过 ω_k 进入高斯阻尼; 谐波前因子则由 w_i 、 R_i 和 d_i 共同确定。把 σ/P 与直接量化阈值比较可以解释尺度, 具体构造由完整系数评价。

下面给出截断傅里叶级数的严格尾界。该上界要求 $\sigma > 0$ 且截断阶数 $L \in \mathbb{N}$ 、 $L \geq 1$ 。当 $\sigma = 0$ 时, 高斯阻尼消失, 相关傅里叶尾项失去绝对可和性, 应改用确定性映射。定义两侧绝对系数尾和

$$R_j(L) := \sum_{|k| > L} |C_{j,k}|, \quad j \in \{1, 2\}, \quad (15)$$

并定义任意实周期函数的半极差

$$\mathcal{A}[f] = \frac{1}{2} \left(\sup_s f(s) - \inf_s f(s) \right).$$

由三角不等式, 若保留 $|k| \leq L$, 则

$$\begin{aligned} \mathcal{A}[B] &\leq \sum_{0 < |k| \leq L} |C_{1,k}| + R_1(L), \\ \max_s |B(s)| &\leq |\bar{B}| + \sum_{0 < |k| \leq L} |C_{1,k}| + R_1(L), \\ \mathcal{A}[M_2] &\leq \sum_{0 < |k| \leq L} |C_{2,k}| + R_2(L). \end{aligned} \quad (16)$$

令

$$C_J = \frac{1}{P} \sum_i |J_i|, \quad C_D = \frac{1}{P} \sum_i |\alpha_i^2 - \beta_i^2|, \\ a = \frac{2\pi^2 \sigma^2}{P^2}.$$

并记

$$\begin{aligned} I_0(L) &= \frac{\sqrt{\pi}}{2\sqrt{a}} \operatorname{erfc}(\sqrt{a}L), \\ I_1(L) &= \frac{1}{2} E_1(aL^2), \\ I_2(L) &= \frac{I_0(L)}{L^2}. \end{aligned}$$

由于 e^{-ax^2} 、 e^{-ax^2}/x 与 e^{-ax^2}/x^2 在 $x > 0$ 单调递减, 积分判别给出两侧尾项的显式上界

$$\begin{aligned} R_1(L) &\leq \bar{R}_1(L) := \frac{C_J P}{\pi} I_1(L), \\ R_2(L) &\leq \bar{R}_2(L) := 2 \left[\frac{C_J P^2}{2\pi^2} I_2(L) + \frac{C_D P}{2\pi} I_1(L) \right. \\ &\quad \left. + 2\sigma^2 C_J I_0(L) \right]. \end{aligned} \quad (17)$$

这里 erfc 是互补误差函数, $E_1(z) = \int_z^\infty e^{-t} t^{-1} dt$ 是指数积分。上述界由有限个精确系数和解析尾项组成, 可严格控制全部高次谐波。式 (16) 的前两行分别控制一阶相位半极差与包含直流项的绝对偏差, 第三行控制二阶相位半极差; 相位平均能量由式 (18) 给出。增加 L 或直接求全局极值可进一步收紧界值。

命题 4 (周期表的相位上界): 设 $T(n+P) = T(n) + P$, $N \sim \mathcal{N}(0, \sigma^2)$ 、 $\sigma > 0$, 且 N 与确定性输入 s 独立。由式 (13)–(14)、尾和定义 (15) 及尾界 (17), 式 (16) 分别给出一阶相位半极差、一阶绝对偏差和二阶相位半极差的上界, 其中绝对一阶偏差包含式 (12) 的 $|\bar{B}|$ 。

非均匀量化的经典平均失真背景见 [14], [13]。对一个有限周期直接积分可得下列精确恒等式; 该结果无需高分辨率近似:

$$E_q = \frac{\sum_i (w_i^3/12 + w_i d_i^2)}{\sum_i w_i}. \quad (18)$$

中心重建时 $d_i = 0$ 。固定 P 与 G 时, 凸性给出 $\sum_i w_i^3 \geq G(P/G)^3$, 等号当且仅当各组等宽。该式只含各组宽度, 不含排列信息; 条件矩的相位极差还需完整周期结构。周期表的平均失真与相位调制因此是两个不同的设计量。

C. 整数重建的附加约束

若设计另行要求 $R_i \in \mathbb{Z}$ 且相位平均误差为零, 即 $\bar{B} = 0$, 则必须满足

$$\sum_i w_i d_i = 0.$$

奇数组宽的中心为整数，偶数组宽的中心为半整数；因此偶数组宽对应 $d_i \in \mathbb{Z} + \frac{1}{2}$ ，偶数组宽仍可满足约束。例如两个等宽偶数组配 $d = (\frac{1}{2}, -\frac{1}{2})$ 即满足整数重建与零直流。小数黑电平校正、查表重建和非整数输出分别对应不同的重建约束。

对固定标度为 4 的整数重建，还可附加同余约束 $R_i \in 4\mathbb{Z} + \beta$, $\beta \in \mathbb{Z}$ 。若同时要求严格递增、平均组宽为 4，则周期内相邻重建值的间距必为 4。令 $\delta_i = e_i - (R_i + 2)$ ，可逐项得到

$$\begin{aligned} w_i &= 4 + \delta_i - \delta_{i-1}, \\ d_i &= -\frac{1}{2}(\delta_i + \delta_{i-1}), \\ \sum_i w_i d_i &= -4 \sum_i \delta_i. \end{aligned}$$

输入码为整数且边界位于相邻码之间时， $\delta_i \in \mathbb{Z} + \frac{1}{2}$ 。故零直流等价于 $\sum_i \delta_i = 0$ ，并立即推出 G 为偶数。正组宽条件给出 $\delta_i - \delta_{i-1} \geq -3$ ；结合零和条件可得有限的解析界

$$\max_i |\delta_i| \leq \frac{3}{2}(G-1).$$

证明如下。令 $M = \max_i \delta_i$ ，从取到 M 的位置沿周期前进 j 步，有 $\delta_{i+j} \geq M - 3j$ ；对 $j = 0, \dots, G-1$ 求和并使用 $\sum_i \delta_i = 0$ ，得到 $M \leq 3(G-1)/2$ 。令 $m = \min_i \delta_i$ ，沿反方向同理有 $\delta_{i-j} \leq m + 3j$ ，求和得到 $m \geq -3(G-1)/2$ 。两式合并即得上界。该界对任意可行的偶数 G 均可达：取 $\delta_j = 3(G-1)/2 - 3j$ ， $j = 0, \dots, G-1$ ，则 $\sum_j \delta_j = 0$ 且 $\delta_j \in \mathbb{Z} + \frac{1}{2}$ ；相应组宽除一个为 $3G+1$ 外其余均为 1，并取到 $\max_j |\delta_j| = 3(G-1)/2$ 。ties-to-even 对应交替的 $\delta_i = \pm \frac{1}{2}$ ，从而直接推出 5,3 交替组宽。上述同余、严格递增、平均组宽与零直流条件构成这一解析界的约束集。

D. 平滑曲线的直流偏置

对缓慢变化、以局部组中心重建且远离端点的压扩曲线，高分辨率展开的领先项为 [9]

$$\bar{B}(m) \simeq \frac{1}{12} \frac{d\Delta^2(m)}{dm}.$$

因此在仿射方差模型 $\Delta^2(m) = (\sigma_0^2 + m/K)/r^{*2}$ 下，领先项为常数

$$\bar{B} = \frac{1}{12Kr^{*2}}.$$

上式是缓慢变化连续曲线的局部渐近式。常数项可由校正吸收，在堆栈平均后仍然保留，与周期表的零均值相位谐波分属两种结构。

X. 结论

在本文指定的独立同分布高斯模型且 $\sigma > 0$ 时，直接量化的一阶条件均值和二阶误差能量都可写成绝对收敛的相位级数，非零谐波随无量纲比值 $r = \sigma/\Delta$ 指数衰减。完整级数上界给出直接 Q_4 绝对一阶偏置、 $Q_4 - Q_1$ 条件均值差与二阶半极差的容差阈值。对 ties-to-even 两级映射，舍入定义产生 5,3 交替单元，完整离散高斯转移概率给出相应条件矩及容差阈值；该映射有别于均匀 Q_4 的相位平移。

对一般周期压扩表，最小周期 P 决定频率网格，并通过 ω_k 进入高斯阻尼；组宽、判决边界和重建值共同决定谐波前因子。命题 4 用有限个精确系数和 erfc/E_1 尾项给出一阶相位半极差、绝对偏差和二阶相位半极差的上界。式 (18) 给出相位平均量化能量，并将其与平滑曲线的局部直流偏置区分开来。

非高斯噪声的一阶矩由各谐波处的特征函数决定，二阶矩还需相应导数；总方差不足以确定相对于高斯模型的统一次序。在量化前同分布、独立与分层条件下，命题 1 把独立帧差与直接最近邻量化的相位半极差下界联系起来。GFX100 四帧暗场进一步显示，ADC 后整数码差分具有重尾和稳定的 18×6 空间相位结构。

参考文献

- [1] R. M. Gray and D. L. Neuhoff, "Quantization," *IEEE Trans. Inf. Theory*, vol. 44, no. 6, pp. 2325–2383, Oct. 1998, doi: 10.1109/18.720541.
- [2] W. F. Sheppard, "On the Calculation of the Most Probable Values of Frequency-Constants, for Data Arranged According to Equidistant Divisions of a Scale," *Proc. London Math. Soc.*, vol. s1-29, no. 1, pp. 353–380, 1897, doi: 10.1112/plms/s1-29.1.353.
- [3] I. Kollár, "Bias of Mean Value and Mean Square Value Measurements Based on Quantized Data," *IEEE Trans. Instrum. Meas.*, vol. 43, no. 5, pp. 733–739, Oct. 1994, doi: 10.1109/19.328894.
- [4] B. Widrow and I. Kollár, *Quantization Noise: Roundoff Error in Digital Computation, Signal Processing, Control, and Communications*. Cambridge, U.K.: Cambridge Univ. Press, 2008, doi: 10.1017/CBO9780511754661.
- [5] P. Carbone and D. Petri, "Mean Value and Variance of Noisy Quantized Data," *Measurement*, vol. 23, no. 3, pp. 131–144, Apr. 1998, doi: 10.1016/S0263-2241(98)00018-9.
- [6] P. Carbone, "Quantitative Criteria for the Design of Dither-Based Quantizing Systems," *IEEE Trans. Instrum. Meas.*, vol. 46, no. 3, pp. 656–659, Jun. 1997, doi: 10.1109/19.585423.
- [7] E. Martinec, "Noise, Dynamic Range and Bit Depth in Digital SLRs," 2008. [Online]. Available: <https://homes.psd.uchicago.edu/~ejm/pix/20d/tests/noise/>. Accessed: Aug. 22, 2026.

- [8] E. C. Anderson and G. W. Dalke, "Compression Techniques for Substantially Lossless Digital Image Data Storage," U.S. Patent 5 790 705, Aug. 4, 1998.
- [9] G. M. Bernstein, C. Bebek, J. Rhodes, C. Stoughton, R. A. Vanderveld, and P. Yeh, "Noise and Bias in Square-Root Compression Schemes," *Publ. Astron. Soc. Pac.*, vol. 122, no. 889, pp. 336–346, Mar. 2010, doi: 10.1086/651281.
- [10] R. A. Gowen and A. Smith, "Square Root Data Compression," *Rev. Sci. Instrum.*, vol. 74, no. 8, pp. 3853–3861, Aug. 2003, doi: 10.1063/1.1593811.
- [11] S. Barkan, "Methods for Quantizing and Compressing Digital Image Data," U.S. Patent 6 396 422 B1, May 28, 2002.
- [12] B. H. Pillman, W. E. Prentice, and M. E. Napoli, "Statistically Lossless Compression System and Method," U.S. Patent 9 438 899 B1, Sep. 6, 2016.
- [13] W. R. Bennett, "Spectra of Quantized Signals," *Bell Syst. Tech. J.*, vol. 27, no. 3, pp. 446–472, Jul. 1948, doi: 10.1002/j.1538-7305.1948.tb01340.x.
- [14] P. F. Panter and W. Dite, "Quantization Distortion in Pulse-Count Modulation with Nonuniform Spacing of Levels," *Proc. IRE*, vol. 39, no. 1, pp. 44–48, Jan. 1951, doi: 10.1109/JR-PROC.1951.230419.
- [15] S. A. Figueroa, "When Is Double Rounding Innocuous?" *ACM SIGNUM Newslett.*, vol. 30, no. 3, pp. 21–26, Jul. 1995, doi: 10.1145/221332.221334.
- [16] L. Schuchman, "Dither Signals and Their Effect on Quantization Noise," *IEEE Trans. Commun. Technol.*, vol. 12, no. 4, pp. 162–165, Dec. 1964, doi: 10.1109/TCOM.1964.1088973.
- [17] R. A. Wannamaker, S. P. Lipshitz, J. Vanderkooy, and J. N. Wright, "A Theory of Nonsubtractive Dither," *IEEE Trans. Signal Process.*, vol. 48, no. 2, pp. 499–516, Feb. 2000, doi: 10.1109/78.823976.
- [18] A. Delaigle, P. Hall, and A. Meister, "On Deconvolution with Repeated Measurements," *Ann. Statist.*, vol. 36, no. 2, pp. 665–685, Apr. 2008, doi: 10.1214/009053607000000884.
- [19] C. E. DeForest, C. Lowder, D. B. Seaton, and M. J. West, "Square Root Compression and Noise Effects in Digitally Transformed Images," *Astrophys. J.*, vol. 934, no. 2, Art. no. 179, Aug. 2022, doi: 10.3847/1538-4357/ac7f3d.
- [20] *IEEE Standard for Floating-Point Arithmetic*, IEEE Standard 754-2019, Jul. 2019, doi: 10.1109/IEEESTD.2019.8766229.
- [21] B. Widrow, "A Study of Rough Amplitude Quantization by Means of Nyquist Sampling Theory," *IRE Trans. Circuit Theory*, vol. 3, no. 4, pp. 266–276, Dec. 1956, doi: 10.1109/TCT.1956.1086334.
- [22] B. Widrow, I. Kollár, and M.-C. Liu, "Statistical Theory of Quantization," *IEEE Trans. Instrum. Meas.*, vol. 45, no. 2, pp. 353–361, Apr. 1996, doi: 10.1109/19.492748.
- [23] A. B. Sripad and D. L. Snyder, "A Necessary and Sufficient Condition for Quantization Errors to be Uniform and White," *IEEE Trans. Acoust., Speech, Signal Process.*, vol. 25, no. 5, pp. 442–448, Oct. 1977, doi: 10.1109/TASSP.1977.1162977.
- [24] S. P. Lipshitz, R. A. Wannamaker, and J. Vanderkooy, "Quantization and Dither: A Theoretical Survey," *J. Audio Eng. Soc.*, vol. 40, no. 5, pp. 355–375, May 1992.
- [25] J. Vanderkooy and S. P. Lipshitz, "Resolution Below the Least Significant Bit in Digital Systems with Dither," *J. Audio Eng. Soc.*, vol. 32, no. 3, pp. 106–113, Mar. 1984.
- [26] R. M. Gray and T. G. Stockham, "Dithered Quantizers," *IEEE Trans. Inf. Theory*, vol. 39, no. 3, pp. 805–812, May 1993, doi: 10.1109/18.256489.
- [27] A. G. Clavier, P. F. Panter, and D. D. Grieg, "Distortion in a Pulse Count Modulation System," *Trans. AIEE*, vol. 66, no. 1, pp. 989–1005, Jan. 1947, doi: 10.1109/T-AIEE.1947.5059539.
- [28] S. Miller, M. Nezamabadi, and S. Daly, "Perceptual Signal Coding for More Efficient Usage of Bit Codes," *SMPTE Motion Imag. J.*, vol. 122, no. 4, pp. 52–59, May 2013, doi: 10.5594/j18290.
- [29] *DICOM PS3.14 2026c: Grayscale Standard Display Function*, NEMA, 2026. [Online]. Available: <https://dicom.nema.org/medical/dicom/current/output/html/part14.html>. Accessed: Aug. 22, 2026.
- [30] *Image Parameter Values for High Dynamic Range Television for Use in Production and International Programme Exchange*, Recommendation ITU-R BT.2100-3, Feb. 2025.
- [31] *The Present State of Ultra-High Definition Television*, Report ITU-R BT.2246-9, Sep. 2025.
- [32] C. Poynton, *Digital Video and HD: Algorithms and Interfaces*, 2nd ed. Waltham, MA, USA: Morgan Kaufmann, 2012.
- [33] W. D. Pence, R. L. White, and R. Seaman, "Optimal Compression of Floating-Point Astronomical Images Without Significant Loss of Information," *Publ. Astron. Soc. Pac.*, vol. 122, no. 895, pp. 1065–1076, Sep. 2010, doi: 10.1086/656249.
- [34] F. J. Anscombe, "The Transformation of Poisson, Binomial and Negative-Binomial Data," *Biometrika*, vol. 35, no. 3–4, pp. 246–254, Dec. 1948, doi: 10.1093/biomet/35.3-4.246.